Q6. Clustering Algorithm Comparison

```
import numpy as np
import matplotlib as mpl
import matplotlib.pyplot as plt
from matplotlib.cm import get_cmap
from sklearn.datasets import make moons
from sklearn.preprocessing import StandardScaler
from sklearn.metrics.cluster import adjusted_rand_score
from sklearn.metrics.cluster import silhouette_score
                                                       # Criterion used to assess the accuracy of clustering (prediction vs cluster label)
# Criterion used to assess the density of clustering (data vs cluster label)
from sklearn.cluster import AgglomerativeClustering
from sklearn.cluster import DBSCAN
X standardized = StandardScaler().fit transform(X)  # Standardize the given datset
# Assign random cluster label for each data in the datset
random_state = np.random.RandomState(seed=0)
random_clusters = random_state.randint(low=0, high=2, size=len(X))
### Prepare various clustering algorithms
clusterer = [KMeans(n_clusters=2), AgglomerativeClustering(n_clusters=2), DBSCAN()]
 legend.append('Cluster '+ str(label))
clusters = clusterer[i].fit_predict(X_standardized)  # Cluster the standardized dataset with current clusterer
    for label in np.unique(clusters):
       # Plot only the points that correspond to certain cluster label using X_standardized[clusters==label]
# Assign the color to the points in the dataset according to their labels
plt.scatter(X_standardized[clusters==label][:, 0], X_standardized[clusters==label][:, 1], c=cmap.colors[label], label='Cluster '+ str(label))
       legend.append('Cluster '+ str(label))
    plt.legend(legend, loc='best')
   # This plot shows that density of clustering is not an effective criterion for determining the accuracy of clustering algorithm # It is recommended to use the score of clustering algorithm as the criterion for the effectiveness of clustering algorithm
plt.show()
                  Random Clusters
ARI : 0.003091 / Silhouette Score : -0.00
                                                                                  AgglomerativeClustering
ARI: 0.606518 / Silhouette Score: 0.46
                                                                                                                  DBSCAN
ARI : 1.000000 / Silhouette Score : 0.38
                                                  KMeans
ARI : 0.501596 / Silhouette Score : 0.49
                0.5
                                               0.5
                                                                               0.5
                                                                                                               0.5
                                         •
                    ¥
                                               0.0
```

- Clustering 알고리즘을 판단하는 기준으로 Density 의 정도를 사용하는 것은 부적합함.
- 위 그래프에서 DBSCAN 과 K-Means, Agglomerative Clustering 을 비교하면 Density 척도인 Sillhouette Score 는 K-Means 가 제일 높지만 근거리로 가까이 있는 서로 다른 Cluster 를 분리 못 하는 것을 볼 수 있음 .
- Cluster 생성 기준에 중심점 데이터 거리를 주로 반영하는 K-Means 와 Agglomerative Clustering 은 근거리로 가까이 있는 서로 다른 Cluster 를 분리 못 하는 단점이 있음 .
- DBSCAN 은 거리 + Cluster 생성 기준이라는 좀 더 복잡한 기준으로 Clustering 을 하기에 근거리로 가까이 있는 서로 다른 Cluster 를 잘 분리할 수 있음 . 그러나 거리 기준 (eps) 와 Cluster 생성 기준 (min_samples) 에 크게 영향을 받기에 Parameter Tuning 이 쉽지 않음 .